

PREDIKSI LONJAKAN KEDATANGAN PENUMPANG KERETA API ANTARKOTA DI STASIUN BANDUNG BERBASIS MODEL *PROPHET*

Muhammad Haikal Rasyadan¹, Ria Yunita², Adinda Pratiwi³, Vito Raditya Pratama⁴, Tubagus Achmad Aditya⁵, Muhammad Rizky Nurhambali⁶, Akbar Rizki^{*7}

^{1,2,3,4,5,6,7}IPB University, Bogor

Email: ¹rasyadhanhaikal@apps.ipb.ac.id, ²riayunita05ria@apps.ipb.ac.id, ³pratiwiadinda@apps.ipb.ac.id, ⁴vitoraditya@apps.ipb.ac.id, ⁵adityatubagus@apps.ipb.ac.id, ⁶rizkynurhambali@apps.ipb.ac.id, ⁷akbar.ritzki@apps.ipb.ac.id

^{*}Penulis Korespondensi

(Naskah masuk: dd mmm yyyy, diterima untuk diterbitkan: dd mmm yyyy)

Abstrak

Model *Prophet* merupakan salah satu model yang baik dalam meramalkan data deret waktu yang dipengaruhi hari libur. Model *Prophet* terdiri dari tiga komponen utama, yaitu tren, musiman, dan hari libur. Salah satu data yang sangat dipengaruhi oleh hari libur adalah data jumlah kedatangan penumpang di sebuah stasiun. Oleh karena itu, tujuan penelitian ini adalah memprediksi lonjakan jumlah kedatangan penumpang di Stasiun Bandung serta mengevaluasi pengaruh hari libur pada model *Prophet*. Data yang digunakan adalah data harian jumlah penumpang antarkota di Stasiun Bandung sebanyak 550 periode mulai tanggal 1 Maret 2023 hingga 31 Agustus 2024, termasuk hari libur, yaitu lebaran, natal, dan tahun baru. Model *Prophet* yang dicobakan adalah model *Prophet* yang mempertimbangkan hari libur dan model *Prophet* yang tidak mempertimbangkan hari libur. Model *Prophet* dioptimalkan melalui *hyperparameter tuning* pada parameter *changepoint prior scale*, *seasonality prior scale*, dan *seasonality mode*, serta dievaluasi akurasi pemodelannya menggunakan kriteria *time series cross validation* dan *mean absolute percentage error* (MAPE). Hasil penelitian menunjukkan adanya pola musiman yang konsisten dan pengaruh signifikan dari hari libur terhadap jumlah penumpang di Stasiun Bandung. Model yang mempertimbangkan efek hari libur menghasilkan akurasi lebih tinggi dengan MAPE sebesar 23,14% dibandingkan model tanpa efek hari libur dengan MAPE sebesar 65,17%. Hasil prediksi menunjukkan model *Prophet* dengan efek hari libur mampu menangkap pola lonjakan penumpang yang terjadi pada hari libur seperti natal dan tahun baru. Hasil peramalan untuk periode yang akan datang menunjukkan bahwa puncak jumlah penumpang pada akhir tahun 2024 akan terjadi pada 23 Desember 2024 dengan estimasi 6.238 penumpang.

Kata kunci: penumpang, peramalan, prophet, hyperparameter, cross validation

PREDICTING THE SURGE IN INTERCITY TRAIN PASSENGER ARRIVALS AT BANDUNG STATION USING PROPHET MODEL

Abstract

The Prophet model is one of the effective models for forecasting time series data influenced by holidays. The Prophet model consists of three main components which are trend, seasonality, and holidays. One type of data that is greatly affected by holidays is passenger arrival data at a station. This study aims to predict the surge in passenger arrivals at Bandung Station and evaluate the impact of holidays on the Prophet model. The data used consists of daily intercity passenger numbers at Bandung Station over 550 periods from March 1, 2023, to August 31, 2024, including holidays such as Eid, Christmas, and New Year's Day. The Prophet models tested are the Prophet model that considers holidays and the Prophet model that does not consider holidays. The Prophet model is optimized through hyperparameter tuning on the changepoint prior scale, seasonality prior scale, and seasonality mode parameters, and evaluated for model accuracy using time series cross-validation criteria and the mean absolute percentage error (MAPE). The results show a consistent seasonal pattern and a significant effect of holidays on passenger numbers. The model considering holidays yields higher accuracy with a MAPE of 23.14%, compared to 65.17% for the model without holiday effects. The forecasts indicate that the model with holiday effects captures passenger surges during holidays like Christmas and New Year. The forecast for the upcoming period shows that the peak number of passengers at the end of 2024 will occur on December 23, 2024, with an estimate of 6,238 passengers.

Keywords: passenger, forecasting, prophet, hyperparameter, cross validation

1. PENDAHULUAN

Prophet adalah paket sumber terbuka (untuk Python dan R) yang dikembangkan dengan memperkirakan data deret waktu oleh tim *Core Data Science* Facebook untuk memprediksi data deret waktu dengan model aditif, yang mencakup tren *non-linear* dengan musiman tahunan, mingguan, dan harian, serta mempertimbangkan efek hari libur. *Prophet* paling efektif untuk deret waktu yang memiliki pola musiman yang jelas dan cukup banyak data historis. Selain itu, *Prophet* mampu menangani data yang hilang, perubahan tren, dan biasanya cukup kuat dalam menghadapi pencilon (Žunić dkk., 2020). Kelebihan yang dimiliki *Prophet* menjadikan dasar bahwa transportasi menjadi salah satu bidang yang tepat untuk menjelaskan bagaimana metode ini dapat diterapkan secara efektif.

Transportasi dapat didefinisikan sebagai proses yang mencakup pergerakan barang dan orang dari satu lokasi ke lokasi lain. Transportasi memegang peran penting dalam menghubungkan berbagai lokasi geografis karena mempercepat distribusi barang dan memungkinkan mobilitas masyarakat. meningkatnya volume permintaan dalam sistem transportasi menyebabkan implementasi strategi yang efisien menjadi krusial untuk perencanaan dan pengelolaan transportasi yang efektif.

Peramalan menjadi alat yang penting untuk memperkirakan nilai atau pola dari variabel-variabel tertentu di masa depan berdasarkan data historis dan analisis tren. Pada dunia transportasi, peramalan berfungsi untuk memprediksi permintaan layanan, mengoptimalkan rute, serta mengelola infrastruktur dengan lebih baik. Penggunaan metode peramalan yang tepat dapat membantu pemerintah dan penyedia layanan transportasi dalam membuat keputusan yang lebih informasional dan strategis, yang nantinya dapat mengurangi kemacetan dan meningkatkan efisiensi operasional.

Stasiun Bandung, sebagai salah satu pusat transportasi utama di Jawa Barat, memiliki relevansi tinggi terkait kedatangan penumpang. Posisinya sebagai pusat pendidikan, budaya, dan ekonomi, stasiun ini bukan hanya berfungsi sebagai titik transit, tetapi juga sebagai penghubung vital antardaerah. Daya tarik kuliner dan popularitas Bandung sebagai destinasi belanja semakin memperkuat arus kedatangan penumpang, terutama pada hari libur. Fenomena ini mencerminkan kebiasaan masyarakat dalam merencanakan perjalanan, serta dampak signifikan dari hari libur terhadap dinamika sosial dan ekonomi setempat.

Analisis pengaruh hari libur terhadap peningkatan jumlah penumpang di Stasiun Bandung menjadi aspek penting dalam perencanaan transportasi. Penelitian ini bertujuan untuk memantau perkembangan jumlah penumpang di Stasiun Bandung serta memprediksi lonjakan penumpang selama libur akhir tahun 2024. Melalui

pendekatan peramalan menggunakan metode *Prophet*, penelitian ini juga akan mengevaluasi dampak hari libur terhadap akurasi peramalan jumlah penumpang.

2. PENELITIAN TERKAIT

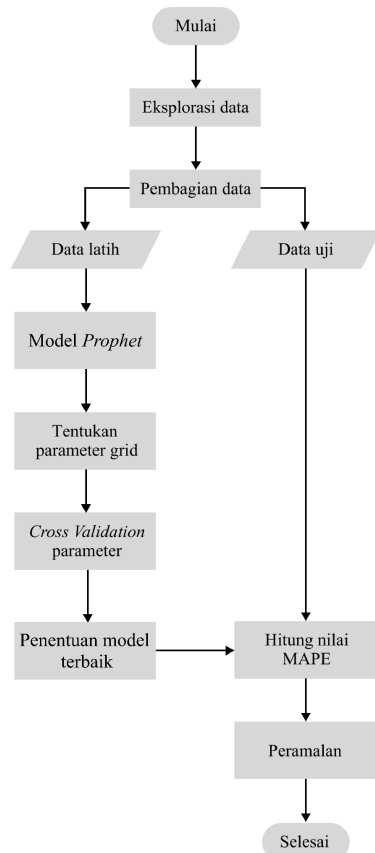
Peramalan jumlah penumpang transportasi umum sebelumnya telah banyak diteliti oleh berbagai pihak salah satunya dalam penelitian Panjaitan, Prahutama, & Sudarsono (2018) melakukan peramalan jumlah penumpang kereta api menggunakan metode *autoregressive integrated moving average* (ARIMA), intervensi, dan *autoregressive fractionally integrated moving average* (ARFIMA). Penelitian tersebut membandingkan dan mengevaluasi ketiga metode berdasarkan *mean squared error* (MSE). Model ARFIMA dipilih sebagai model terbaik karena memiliki nilai MSE terkecil dibandingkan model lainnya. Nilai MSE yang diperoleh yaitu 0,00964 dengan model ARFIMA (0,d,[1,13]) dan $d = 0,367546$. Penelitian lain yaitu Salsabila & Kesumawati (2023) membahas peramalan penumpang transportasi menggunakan metode *double exponential smoothing* (DES). Metode tersebut melakukan pemulusan terhadap data tren sebanyak dua kali dan dihasilkan nilai akurasi peramalan biasa dengan nilai MAPE sebesar 34,89%.

Selain itu, Prakorso, Darmawan, & Bachrudin (2023) yang melakukan peramalan mengenai jumlah penumpang Trans Metro Bandung koridor satu. Penelitian tersebut menggunakan metode *Facebook Prophet* dengan tiga model sebagai perbandingan dan dipilih Model 3 sebagai model terbaik berdasarkan nilai *mean absolute percentage error* (MAPE) terkecil dan *Coverage* (R^2) terbesar. Model 3 merupakan model dengan penambahan *extra regressor* dan efek hari libur nasional di Indonesia. Model tersebut menghasilkan MAPE data latih sebesar 10,99% dan MAPE data uji sebesar 4,62%, dengan nilai R^2 sebesar 89%. Oleh karena itu, berdasarkan berbagai literatur yang telah dikaji, metode *Prophet* dianggap lebih unggul dibandingkan metode lainnya dalam melakukan peramalan pada data dengan pola kompleks, seperti pola musiman dan tren *non-linear* serta data yang sangat dipengaruhi oleh hari libur.

3. METODE PENELITIAN

Penelitian ini menggunakan model berbasis *Prophet* untuk memprediksi jumlah kedatangan penumpang antarkota di Stasiun Bandung. Model *Prophet* dipilih karena keandalannya dalam memprediksi data deret waktu, terutama dalam konteks tren musiman dan variasi siklus (Aziza dkk., 2020). Metode penelitian yang digunakan pada

penelitian ini mencakup beberapa tahapan yang disajikan dalam Gambar 1.



Gambar 1. Diagram alir penelitian

Gambar 1 menunjukkan prosedur penelitian dimulai dengan melakukan eksplorasi data. Setelah memperoleh hasil eksplorasi data, data dibagi menjadi data latih dan data uji. Data latih ini akan dilakukan pemodelan dengan metode *Prophet*, di mana pemodelan *Prophet* dilakukan dengan menentukan nilai *hyperparameter tuning* yang akan dioptimasi menggunakan *cross validation* untuk mengevaluasi berbagai kombinasi parameter. Penentuan model terbaik akan dilakukan berdasarkan nilai MAPE terkecil pada data latih. Selanjutnya, model ini diuji pada data uji untuk menghitung nilai MAPE sebagai bentuk akurasi modelnya. Setelah itu, peramalan dilakukan menggunakan model terbaik yang telah diperoleh.

3.1. Data

Data yang digunakan dalam penelitian ini adalah jumlah kedatangan penumpang kereta api antarkota di Stasiun Bandung, yang mencakup data harian selama 550 hari, mulai dari 1 Maret 2023 hingga 31 Agustus 2024. Data ini diperoleh dari situs siasati.dephub.go.id yang dikelola oleh Kementerian Perhubungan Republik Indonesia. Selain itu, terdapat sejumlah peristiwa khusus yang memengaruhi data deret waktu pada beberapa periode, yaitu libur lebaran, serta natal dan tahun

baru. Periode-periode ini akan dimasukkan ke dalam *holiday function* pada model *Prophet* untuk memperhitungkan pengaruhnya terhadap data.

Data dibagi menjadi dua bagian, yaitu data latih dan data uji. Data latih digunakan untuk membangun model terbaik yang nantinya dapat digunakan untuk peramalan, sementara data uji berfungsi untuk mengevaluasi performa model yang telah dibuat (Meilania dkk., 2024). Pada penelitian ini, data latih terdiri dari 321 data yang mencakup periode dari tanggal 1 Maret 2023 hingga 15 Januari 2024. Sedangkan, data uji terdiri dari 229 periode, dimulai dari tanggal 16 Januari 2024 hingga 31 Agustus 2024.

3.2. Eksplorasi Data

Exploratory Data Analysis (EDA), diperkenalkan oleh Tukey pada tahun 1961, adalah metode untuk merencanakan pengumpulan data guna mempermudah dan meningkatkan akurasi analisis data (Harahap dkk., 2022). Penelitian ini melakukan eksplorasi untuk mengidentifikasi pola pada data jumlah kedatangan penumpang kereta api antarkota di Stasiun Bandung. Pada eksplorasi ini, disajikan pula plot dekomposisi yang membagi plot observasi menjadi pola tren, pola musiman, dan pola acak guna memperlihatkan dengan lebih jelas apakah terdapat indikasi pola musiman pada data.

3.3. Model Prophet

Model *Prophet* mirip dengan *generalized additive model* (GAM) yang fleksibel untuk menangani komponen *non-linear* dalam regresi. Model ini menggunakan waktu sebagai variabel utama dengan beberapa fungsi linier dan *non-linear*, serta memungkinkan pemodelan musiman secara aditif atau multiplikatif (Taylor & Letham, 2017). *Prophet* menggunakan model deret waktu yang dapat diurai (*decomposable time series*) dengan tiga komponen model utama, yaitu tren (*trend*), musiman (*seasonality*), dan hari libur (*holidays*) (Jange, 2022). Menurut Taylor & Letham (2017), Persamaan (1) merupakan persamaan model *Prophet* yang dituliskan sebagai berikut.

$$Y(t) = g(t) + s(t) + h(t) + e_t \quad (1)$$

di mana,

$g(t)$ = *Trend/Growth function*

$s(t)$ = *Seasonality function*

$h(t)$ = *Holiday function*

e_t = *Error*

a. Trend/Growth Function

Menurut Taylor & Letham (2017), peramalan pertumbuhan dapat dilakukan dengan empat opsi, yaitu *non-linear saturating growth*, *linear trend with changepoints*, *automatic changepoint*

selection, dan *trend forecast uncertainty*. *Linear trend with changepoints* digunakan ketika pertumbuhan tidak menunjukkan pertumbuhan yang jenuh. Pilihan ini sangat berguna untuk deret waktu yang mengalami pertumbuhan linier tetapi dengan perubahan laju pada waktu tertentu (Prakoso dkk., 2023). Model ini dirumuskan menjadi Persamaan (2), yaitu:

$$g(t) = (k + a(t)^T \delta)t + (m + a(t)^T \gamma) \quad (2)$$

Menurut Rahman dkk. (2020), komponen k mewakili laju pertumbuhan yang bisa mengalami perubahan dengan mempertimbangkan titik-titik perubahan (*changepoints*) sepanjang periode waktu tertentu. Diasumsikan terdapat S titik perubahan pada waktu s_j dimana titik perubahan ke- j terjadi (dengan $j = 1, 2, \dots, S$). Perubahan dalam laju pertumbuhan yang terjadi pada waktu s_j bisa diwakili oleh sebuah vektor penyesuaian laju ($\delta \in \mathbb{R}^S$). Laju pada setiap waktu (t) merupakan gabungan dari laju dasar (k) dan semua penyesuaian hingga menjadi

$k + \sum_{j:t>s_j} \delta_j$ yang dapat disajikan oleh vektor

$a(t) \in \{0, 1\}^S$, yaitu $a_j(t) = 1$ untuk $t \geq s_j$ dan 0 untuk t lainnya.

Pilihan kedua, yaitu *non-linear saturating growth*, Hutchinson (1978) dalam Taylor dan Letham (2017) menjelaskan bahwa komponen inti dari proses penghasil data adalah model yang menggambarkan bagaimana populasi telah bertumbuh dan bagaimana pertumbuhan tersebut diperkirakan akan berlanjut sehingga diperoleh Persamaan (3), yaitu model *non-linear saturating growth* yang diperluas menjadi:

$$g(t) = \frac{C(t)}{1 + \exp(-(k + a(t)^T \delta)(t - (m + a(t)^T \gamma)))} \quad (3)$$

Meskipun tanggal-tanggal penting telah diketahui sebelumnya, banyaknya data historis membuat penentuan titik perubahan secara manual menjadi sulit. Oleh karena itu diterapkan *automatic changepoint selection*, yang memungkinkan penentuan titik perubahan secara otomatis. Pada proses ini, diterapkan sebuah vektor untuk mengatur tingkat penyesuaian ($\delta \in \mathbb{R}^S$) digunakan untuk menunjukkan lokasi terjadinya perubahan ke dalam Persamaan (2) dan (3). Titik-titik perubahan ini diidentifikasi dengan melewati nilai-nilai dalam prior $\delta_j \sim \text{laplace}(0, \tau)$, di mana parameter τ

mengendalikan fleksibilitas model (Srivastava, 2019).

b. Seasonality Function

Model *Fourier* digunakan untuk menangkap pola musiman menggunakan kombinasi fungsi sinus dan cosinus dengan membentuk fungsi periodik yang mampu meniru perubahan musiman dalam data (Harvey & Shephard, 1993; Taylor & Letham, 2017) sehingga Persamaan (4) menjadi persamaan untuk model *seasonal* yang dituliskan sebagai berikut.

$$s(t) = \sum_{n=1}^N (a_n \cos(\frac{2\pi nt}{P}) + (b_n \sin(\frac{2\pi nt}{P}))) \quad (4)$$

di mana,

$$a_n = \frac{1}{P} \int_{-P}^P f(x) \cos(\frac{2\pi nt}{P}) dx$$

$$b_n = \frac{1}{P} \int_{-P}^P f(x) \sin(\frac{2\pi nt}{P}) dx$$

N = Nilai harmonik yang digunakan

P = Periode reguler yang diharapkan

Pemilihan periode reguler (P) dan parameter N bergantung pada jenis data musiman. Nilai $P = 365,25$ digunakan untuk data tahunan dan $P = 7$ untuk data mingguan. Nilai N kecil menghasilkan model yang lebih halus tetapi kurang responsif terhadap pola musiman, sementara N besar menangkap pola lebih rinci namun berisiko *overfitting*. Pada data mingguan, $P = 7$ dan $N = 3$ dianggap efektif, dan pemilihan parameter ini dapat diotomatisasi menggunakan kriteria AIC (Taylor & Letham, 2017).

c. Holiday Function

Model *Prophet* memungkinkan analisis menyediakan daftar kustom dari liburan atau peristiwa yang mencakup tanggal-tanggal masa lalu dan masa depan dari peristiwa tersebut. Setiap liburan diidentifikasi dengan nama yang unik, dan daftar ini dapat disesuaikan untuk liburan yang berlaku secara global maupun spesifik untuk suatu negara (Taylor & Letham, 2017). Menurut Prakoso dkk. (2023), hari libur (i), baik yang sudah berlalu maupun yang akan datang, direpresentasikan dengan simbol D_i . Simbol t menunjukkan durasi masing-masing hari libur, di mana setiap hari libur diwakili oleh κ_i sehingga membentuk Persamaan (5) dan (6) yang menyerupai komponen musiman dengan penyusunan matriks regresi, sebagai berikut.

$$\mathbf{Z}(t) = [1(t \in D_1), \dots, 1(t \in D_L)] \quad (5)$$

dan

$$h(t) = \mathbf{Z}(t)\kappa \quad (6)$$

Matriks $\mathbf{Z}(t)$ mengumpulkan semua informasi hari libur yang dipertimbangkan dalam model yang dibangun dengan setiap kolom mewakili satu hari libur. Parameter κ diasumsikan mengikuti distribusi Normal, $\kappa \sim \text{Normal}(0, v^2)$, untuk mengatur dampak liburan dalam model dan mencegah *overfitting* (Taylor & Letham, 2017).

Pada model *Prophet*, peramalan dimulai dengan visualisasi data sebagai langkah awal dalam membangun model. Tahap berikutnya adalah membentuk model dengan menyesuaikan parameter tren, musiman, hari libur, dan komponen lainnya. Setelah itu, dilakukan evaluasi terhadap model peramalan. Jika hasil evaluasi terhadap model menunjukkan hasil yang baik maka proses dapat dilanjutkan ke tahap peramalan (Prakoso dkk., 2023).

Oleh karena itu, penelitian ini menggunakan *automatic trend selection* dengan parameter $P = 7$ dan $N = 3$ untuk menangani musiman mingguan dalam data. Model dengan komponen hari libur juga disesuaikan dengan hari libur khusus, yaitu natal dan tahun baru, karena pola data menunjukkan adanya lonjakan signifikan pada kedua periode tersebut. Selain itu, model *Prophet* dibangun dengan dua penyesuaian parameter, yaitu model dengan komponen liburan dan tanpa komponen liburan untuk mengidentifikasi pengaruh liburan terhadap model.

3.4. Hyperparameter Tuning

Hyperparameter tuning merupakan proses optimasi untuk menentukan kombinasi parameter terbaik dalam model *machine learning*, termasuk model *Prophet* yang dikembangkan oleh Facebook. Nilai parameter ditetapkan sebelum proses pelatihan sehingga pemilihan nilai parameter yang tepat sangat penting untuk meningkatkan performa model (Putri, Widiyari, & Santoso 2022). Pada model *Prophet*, terdapat beberapa parameter utama untuk menghasilkan pemodelan *Prophet* yang optimal. Berikut merupakan *hyperparameter tuning* yang digunakan dalam penelitian ini.

a. Changepoint Prior Scale

Changepoint prior scale merupakan parameter yang menentukan fleksibilitas dari suatu tren dengan menyesuaikan jumlah *changepoint*. Nilai *changepoint* yang tinggi dapat meningkatkan fleksibilitas model terhadap tren, sedangkan nilai yang rendah dapat mengurangi fleksibilitas pada model (Raihan, Suhendi, & Bethaningtyas, 2023). Penelitian ini menggunakan nilai *changepoint prior scale* dilakukan pada nilai 0,01; 0,05; 0,1; dan 0,5.

b. Seasonality Prior Scale

Seasonality prior scale merupakan parameter yang mengatur kekuatan efek musiman dalam model. Nilai parameter yang semakin tinggi

memungkinkan model untuk menangkap variasi musiman dengan lebih besar, sedangkan nilai parameter yang rendah menghasilkan model dengan variasi musiman yang lebih rendah (Raihan, Suhendi, & Bethaningtyas, 2023). Nilai *seasonality prior scale* yang digunakan dalam penelitian ini yaitu sebesar 1,5, 10, dan 15.

c. Seasonality Mode

Seasonality mode merupakan parameter yang memungkinkan pemilihan pola tren yang terdiri dari dua jenis yaitu *additive* dan *multiplicative*. Pola *additive* merupakan pola yang menunjukkan bahwa perubahan nilai cenderung tetap seiring waktu, sedangkan pola *multiplicative* menunjukkan bahwa perubahan nilai bersifat dinamis seiring waktu (Raihan, Suhendi, & Bethaningtyas, 2023). Pada penelitian ini, kedua jenis *seasonal mode* diatur untuk mengetahui pola yang paling sesuai dalam model.

d. Holiday Prior Scale

Holiday prior scale merupakan parameter yang mengukur kekuatan hari libur dalam model. Nilai *holiday prior scale* yang tinggi akan membentuk model yang lebih fleksibel dalam menangkap fluktuasi yang disebabkan oleh hari libur, sedangkan nilai yang lebih rendah akan membentuk model yang fluktuasi nya lebih halus dan mengurangi pengaruh hari libur (Sukma, 2024). Nilai *holiday prior scale* diatur dalam penelitian ini yaitu sebesar 1,5, 10, dan 15.

3.5. Time Series Cross Validation

Time series cross validation merupakan teknik yang digunakan untuk mengevaluasi model peramalan deret waktu dengan cara melatih model pada data masa lalu dan menguji prediksinya pada data yang lebih baru sehingga menghasilkan kinerja model yang lebih akurat dalam peramalan. Pada proses ini, data akan dibagi menjadi tiga bagian yaitu *initial*, *cutoff*, dan *horizon*. Bagian *initial* digunakan untuk melatih model, *cutoff* untuk validasi, dan *horizon* untuk menghasilkan ramalan di antara titik *cutoff* dan *horizon* (Prakorso dkk., 2023). Penelitian ini menggunakan *initial* sebanyak 200, *cutoff* 30, dan *horizon* 60 periode.

3.6. Evaluasi Model dengan MAPE

Evaluasi model dilakukan dengan memilih model berdasarkan pengukuran kesalahan terkecil pada beberapa kombinasi parameter yang diperoleh setelah dilakukan pelatihan model menggunakan *cross validation*. Pengukuran kesalahan yang sering digunakan untuk menentukan model terbaik adalah MAPE. Hal ini karena MAPE mengukur perbedaan antara nilai ramalan dan nilai aktual dalam bentuk persentase sehingga sesuai untuk mengukur

ketepatan suatu model. Lewis (1982) dalam Falatouri dkk. (2022) mengategorikan MAPE dalam empat kategori, yaitu ketika $MAPE < 10\%$ (model sangat akurat), $MAPE 10\%-20\%$ (model akurat), $MAPE 20\%-50\%$ (model cukup akurat), dan $MAPE > 50\%$ (model buruk).


3.7. Peramalan

Peramalan merupakan proses memperkirakan nilai di masa depan dengan menggunakan data masa lalu. Peramalan ini dilakukan pada model optimum yang memiliki nilai MAPE terkecil. Jika terdapat transformasi dalam proses pemodelan, maka data yang akan diramalkan harus ditransformasi kembali ke nilai aslinya (Prakorso dkk., 2023). Pada penelitian akan dilakukan peramalan dari 01 September 2024 sampai 08 Januari 2025 untuk memprediksi jumlah penumpang antarkota Stasiun Bandung di akhir tahun.


4. HASIL DAN PEMBAHASAN

4.1. Eksplorasi Data


Jumlah kedatangan penumpang antarkota kereta api di Stasiun Bandung terdapat pola data yang menunjukkan sifat musiman. Hal ini dapat terlihat pada Gambar 2a. Meskipun terdapat penurunan intensitas fluktuasi di sekitar pertengahan tahun 2024, tren jangka panjang terlihat relatif stabil tanpa kenaikan atau penurunan drastis, namun lonjakan sesaat menunjukkan bahwa faktor eksternal, seperti liburan atau peristiwa khusus, sangat memengaruhi jumlah penumpang. Oleh karena itu, dilakukan dekomposisi untuk mengetahui lebih lanjut mengenai pola musiman dan pola tren liburan yang terjadi.



Gambar 2a. Plot deret waktu




Gambar 2b. Plot dekomposisi musiman



Gambar 2c. Plot dekomposisi tren dan pola lonjakan liburan

Eksplorasi data jumlah kedatangan penumpang antarkota kereta api di Stasiun Bandung menunjukkan adanya pola musiman mingguan yang konsisten. Gambar 2b memberikan informasi, pola *seasonal* tampak stabil dan teratur, mencerminkan fluktuasi musiman yang berulang secara periodik setiap pekan. Pola ini terlihat bersifat konstan atau *additive*, yang berarti pengaruh musiman memberikan kontribusi tetap terhadap tren utama tanpa perubahan yang berlebihan.

Gambar 2c menunjukkan lonjakan besar dalam beberapa rentang waktu tertentu. Sebagai contoh, pada Desember 2023 dan April 2024 terjadi peningkatan jumlah kedatangan penumpang yang cukup tinggi. Sebanyak 9.871 penumpang tercatat pada tanggal 23 Desember 2023, yaitu dua hari sebelum perayaan natal, dan sebanyak 13.171 penumpang tercatat pada tanggal 12 April 2024, yaitu dua hari setelah hari raya lebaran. Hal ini menunjukkan bahwa jumlah kedatangan penumpang di Stasiun Bandung dipengaruhi oleh periode libur nasional, khususnya liburan perayaan keagamaan besar di Indonesia. Selanjutnya data tersebut dibagi menjadi data latih dan data uji seperti yang ditampilkan pada Gambar 3.



Gambar 3. Plot pembagian data latih dan data uji

Informasi yang diperoleh dari Gambar 3, proporsi yang digunakan untuk pembagian data sebesar 321 periode untuk data latih dan 229 periode untuk data uji. Pembagian ini dipilih karena cenderung menghasilkan pola yang serupa antara kedua set data sehingga data uji dapat mencerminkan karakteristik yang ada pada data latih. Dengan demikian, model yang dibangun berdasarkan data

latih memiliki peluang lebih besar untuk diterapkan dengan baik pada data uji.

4.2. Model *Prophet* tanpa Efek Liburan

Tahap awal dalam pemodelan menggunakan *Prophet* adalah melakukan *hyperparameter tuning*. Proses ini dilakukan dengan mengombinasikan berbagai *hyperparameter* yang digunakan dalam model *Prophet* melalui teknik *cross-validation* untuk menentukan kombinasi *hyperparameter* terbaik (Sukma, 2024). Teknik *cross-validation* ini membagi data menjadi beberapa subset yaitu *initial*, *cutoff*, dan *horizon*.


Data *initial* yang digunakan sebesar 200 yang berarti model akan dilatih menggunakan data sebanyak 200 periode pertama pada setiap iterasi. Setelah model dilatih, data *horizon* sebesar 60 periode berikutnya akan digunakan untuk memvalidasi hasil prediksi model dengan cara membandingkannya terhadap data aktual. Kemudian, untuk iterasi selanjutnya, data pelatihan akan ditambahkan sebanyak 30 periode sehingga model akan kembali dilatih dengan menggunakan 230 periode data dan divalidasi kembali selama 60 periode berikutnya. Proses ini diulang secara iteratif sampai seluruh data latih digunakan dalam pelatihan dan validasi.

Hasil proses ini, dapat terlihat pada Tabel 1 diperoleh 32 model yang merupakan kombinasi berbagai *hyperparameter*. Hasil analisis memberikan informasi bahwa model 21 memiliki nilai MAPE untuk data latih terkecil, yaitu sebesar 15,25%. Oleh karena itu, *hyperparameter* terbaik terdapat pada model 21, dengan nilai *changepoint prior scale* sebesar 0,1, *seasonality prior scale* sebesar 10, dan *seasonality mode* bersifat *additive*.

Parameter terbaik dengan nilai *changepoint prior scale* sebesar 0,1 memungkinkan model melakukan penyesuaian kecil terhadap titik perubahan, hal ini menunjukkan bahwa *trend* dalam data tidak terlalu besar. Sedangkan, nilai *seasonality prior scale* sebesar 10 menunjukkan bahwa pendeteksian perubahan musiman dalam data cukup tinggi sehingga model mampu menangkap variasi musiman yang kompleks. Mode musiman *additive* berarti bahwa efek musiman dianggap konstan di seluruh *trend*. Kombinasi parameter ini akan digunakan untuk analisis lebih lanjut.

Tabel 1. Hasil <i>Hyperparameter</i> Model Tanpa Efek Liburan				
No.	Prior Scale		Seasonality Mode	MAPE (%)
	Changepoint	Seasonality		
1	0,01	1	<i>additive</i>	23,40
2	0,01	1	<i>multiplicative</i>	23,88
3	0,01	5	<i>additive</i>	23,88
⋮	⋮	⋮	⋮	⋮
21	0,1	10	<i>additive</i>	15,25
⋮	⋮	⋮	⋮	⋮
32	0,5	15	<i>multiplicative</i>	17,90

Setelah menentukan kombinasi *hyperparameter* terbaik, proses peramalan dilakukan pada data uji. Hasil peramalan menggunakan model ini menunjukkan nilai MAPE sebesar 65,17% pada data uji. Hal ini menunjukkan bahwa hasil peramalan model *Prophet* tanpa mempertimbangkan efek liburan memiliki tingkat akurasi yang sangat rendah, sebagaimana ditunjukkan oleh nilai MAPE yang tinggi pada data uji. Sesuai dengan kriteria akurasi peramalan, nilai MAPE sebesar ini mengindikasikan bahwa model tidak mampu menghasilkan prediksi yang memadai pada data uji sehingga termasuk ke dalam model yang buruk (Pontoh dkk., 2021). Selain itu, Gambar 4 memperkuat bukti bahwa model ini tergolong buruk, terlihat dari plot hasil peramalan yang memiliki pola sangat berbeda dibandingkan dengan plot data aktual pada data uji.



Gambar 4. Plot perbandingan uji peramalan dengan data aktual yang tidak mempertimbangkan efek liburan

Pola hasil peramalan data uji tidak sepenuhnya mengikuti pola data aktual, khususnya pada periode liburan dimana pola lonjakan ketika liburan tidak teridentifikasi pada model ini. Hal ini juga menjadi salah satu faktor yang menyebabkan nilai MAPE data uji pada model ini cenderung besar. Oleh karena itu, model ini tidak dapat secara otomatis membaca efek liburan dari data sehingga diperlukan pemodelan lain dengan memasukkan komponen liburan.

4.3. Model *Prophet* dengan Efek Liburan

Model *Prophet* dengan efek liburan dilakukan dengan membuat kerangka hari libur yang terdiri dari liburan lebaran, serta natal dan tahun baru. Proses pemodelan dilakukan sama seperti model *prophet* tanpa efek liburan yaitu dengan melakukan *hyperparameter tuning* dan *cross validation*, hanya pada model ini ditambahkan parameter *holiday prior scale*. Pada proses pemodelan ini, diperoleh 128 model yang merupakan kombinasi *hyperparameter*. Tabel 2 menunjukkan bahwa model 33 merupakan model terbaik karena memiliki nilai MAPE terkecil dibandingkan model lainnya. Nilai MAPE data latih pada model 33 yaitu sebesar 15,47% dengan nilai *changepoint prior scale* sebesar 0,05, *seasonality*

prior scale sebesar 1, *holiday prior scale* sebesar 1, dan *seasonality mode* bersifat *additive*.

Tabel 2. Hasil *Hyperparameter* Model dengan Efek Liburan

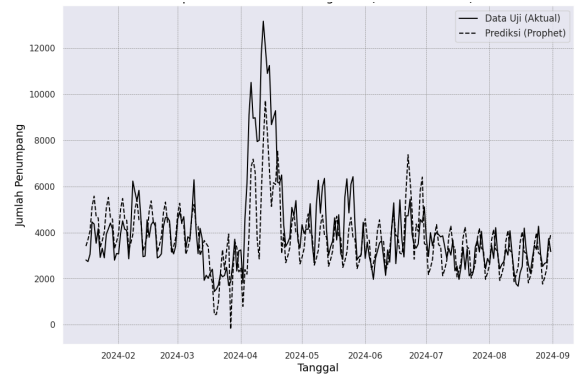
No.	<i>Prior Scale</i>			<i>Seasonality Mode</i>	MAPE (%)
	<i>Change-point</i>	<i>Seasonality</i>	<i>Holiday</i>		
1	0,01	1	1	<i>additive</i>	19,43
2	0,01	1	5	<i>additive</i>	18,44
3	0,01	1	10	<i>additive</i>	19,92
⋮	⋮	⋮	⋮	⋮	⋮
33	0,05	1	1	<i>additive</i>	15,47
⋮	⋮	⋮	⋮	⋮	⋮
128	0,5	15	15	<i>multiplicative</i>	17,77

Parameter terbaik dengan nilai *changepoint prior scale* sebesar 0,05, *seasonal prior scale* dan *holiday prior scale* masing-masing sebesar 1, serta penggunaan *mode* musiman *additive* dalam model menunjukkan pengukuran yang lebih menyesuaikan perubahan fluktuasi data dan cenderung stabil. Pada *changepoint prior scale* yang rendah, model hanya akan melakukan penyesuaian kecil pada titik perubahan yang terdeteksi. Hal ini menunjukkan bahwa *trend* dalam data tidak terlalu besar. Sementara itu, nilai *seasonality* dan *holiday prior scale* yang sama menunjukkan pendekatan yang konsisten terhadap efek musiman dan hari libur tanpa penyesuaian berlebihan. *Mode* musiman *additive* berarti bahwa efek musiman dianggap konstan di seluruh tren sehingga model lebih cocok untuk data dengan pola musiman yang stabil dan tidak berubah seiring waktu.

Tabel 3 menyajikan perbandingan nilai MAPE antara model *Prophet* yang mempertimbangkan efek liburan dan yang tidak. Model *Prophet* dengan mempertimbangkan efek liburan menghasilkan prediksi yang cukup akurat dengan nilai MAPE yang lebih rendah, yaitu 23,14% pada data uji dan 15,47% pada data latih. Hasil ini menunjukkan peningkatan akurasi yang cukup tinggi dibandingkan dengan model *Prophet* yang tidak mempertimbangkan efek liburan. Akurasi nilai MAPE ini juga dapat digambarkan dari Gambar 5 yang menunjukkan plot perbandingan data aktual dan peramalan dari data uji.

Tabel 3. Perbandingan Nilai MAPE Data Uji

Model	MAPE (%)
Tanpa liburan	65,17
Dengan liburan	23,14




Gambar 5. Plot perbandingan data uji peramalan dengan data aktual yang mempertimbangan efek liburan

Plot hasil peramalan data uji pada model *Prophet* dengan efek liburan pada Gambar 5 menunjukkan hasil yang tidak jauh berbeda dari data aktual, yang mengindikasikan bahwa model telah berhasil menangkap pola musiman dan lonjakan yang terjadi selama periode liburan. Pada kasus ini, model *Prophet* dapat mengenali adanya peningkatan jumlah kedatangan penumpang pada hari-hari tertentu yang bertepatan dengan liburan, seperti yang terlihat pada lonjakan sekitar natal dan lebaran. Hasil ini menunjukkan bahwa pertimbangan terhadap faktor musiman seperti liburan sangat penting dalam meningkatkan akurasi peramalan pada model *Prophet* karena dapat menghasilkan model terbaik dengan nilai MAPE yang kecil.


4.4. Hasil Peramalan

Peramalan dilakukan menggunakan model terbaik. Model terbaik didapatkan setelah melakukan *hyperparameter tuning* dengan teknik *cross validation* dan evaluasi model dengan membandingkan nilai MAPE terkecil. Model terbaik ini meliputi nilai *changepoint prior scale* sebesar 0,05, *seasonality prior scale* sebesar 1, *holiday prior scale* sebesar 1, dan *seasonality mode* yang bersifat *additive*. Peramalan ini dimulai dari tanggal 01 September 2024 sampai 08 Januari 2025.

Hasil peramalan yang dilakukan dengan model terbaik menunjukkan adanya tren penurunan jumlah penumpang setiap bulannya. Hal ini dapat dilihat dari plot trend yang disajikan dalam gambar 6a, dimana plot ini menunjukkan bahwa jumlah penumpang datang Stasiun Bandung secara keseluruhan mengalami penurunan. Namun, pada Gambar 6b dapat dilihat bahwa dalam hasil peramalan ini terdapat lonjakan jumlah penumpang yang terjadi selama periode natal dan tahun baru.



Gambar 6a. Plot tren jumlah penumpang datang Stasiun Bandung



Gambar 6b. Plot ramalan hingga awal tahun 2025

Hasil peramalan untuk 130 periode kedepan menunjukkan bahwa jumlah penumpang tertinggi diprediksi akan terjadi pada tanggal 23 Desember 2024, dengan estimasi 6.238 penumpang. Hal ini dapat terjadi karena tanggal tersebut merupakan dua hari sebelum perayaan natal sehingga banyak masyarakat yang melakukan perjalanan pulang kampung. Selain itu, jumlah penumpang diprediksi tetap tinggi selama periode 27–30 Desember 2024, dengan kisaran antara 5.000 hingga 6.000 penumpang. Tingginya angka ini diduga karena periode tersebut berdekatan dengan tahun baru, di mana banyak orang melakukan perjalanan untuk mudik atau merayakan pergantian tahun di luar kota.

5. KESIMPULAN

Model *Prophet* dengan efek liburan memberikan hasil akurasi yang lebih baik dengan nilai *changepoint prior scale* sebesar 0,05, *seasonality prior scale* sebesar 1, *holiday prior scale* sebesar 1, dan *seasonality mode* yang bersifat *additive*. Model ini menghasilkan nilai MAPE sebesar 23,14% pada data uji dan 15,47% pada data latih. Model tersebut dinilai lebih unggul karena dapat menangkap pola lonjakan penumpang pada libur lebaran serta natal dan tahun baru dengan lebih akurat. Hasil peramalan jumlah penumpang di Stasiun Bandung menunjukkan bahwa jumlah penumpang datang di Stasiun Bandung secara keseluruhan mengalami penurunan, hal ini diindikasikan dengan adanya tren penurunan jumlah penumpang setiap bulannya. Hasil peramalan selama liburan akhir tahun 2024 menunjukkan bahwa model *Prophet* mampu menangkap efek natal dan tahun baru. Selain itu hasil peramalan menunjukkan puncak jumlah penumpang pada akhir tahun 2024 terjadi pada 23 Desember 2024 dengan estimasi mencapai 6.238 penumpang.

6. DAFTAR PUSTAKA

- AZIZA, V.N., MOH'D, F.H., MAGHFIROH, F.A., NOTODIPUTRO, K.A. AND ANGRAINI, Y., 2023. PERFORMANCE COMPARISON OF SARIMA INTERVENTION AND PROPHET MODELS FOR FORECASTING THE NUMBER OF AIRLINE PASSENGER AT SOEKARNO-HATTA INTERNATIONAL AIRPORT. *BAREKENG: Jurnal Ilmu Matematika dan Terapan*, 17(4), pp.2107–2120. <https://doi.org/10.30598/barekengvol17iss4pp2107-2120>.
- FALATOURI, T., DARBANIAN, F., BRANDTNER, P. AND UDOKWU, C., 2022. Predictive Analytics for Demand Forecasting – A Comparison of SARIMA and LSTM in Retail SCM. *Procedia Computer Science*, 200, pp.993–1003. <https://doi.org/10.1016/j.procs.2022.01.298>.
- HARAHAP, M., ZAKI ANDIKA, A., HUSEIN, A.M. AND DHARMA, A., 2022. Analisis Tren dan Perkiraan Pandemi Covid-19 Di Indonesia Menggunakan Peramalan Metode Prophet: Sebelum dan Sesudah Aturan New Normal. *Jurnal Teknologi Informasi dan Ilmu Komputer (JTIK)*, [online] 9(1), pp.51–60. <https://doi.org/10.25126/jtiik.202294060>.
- HARVEY, A.C. AND SHEPHARD, N., 1993. Structural Time Series Models. In: G.S. Maddala, C.R. Rao and H.D. Vinod, eds. *Handbook of Statistics*, 11th ed. Elsevier Science Publishers B.V. pp.261–302.
- HUTCHINSON, G.E., 1978. *An Introduction to Population Ecology*. New Haven: Yale University Press.
- JANGE, B., 2022. Prediksi Indeks Harga Saham Gabungan (IHSG) Menggunakan Prophet. *Jotika: Journal In Management And Entrepreneurship*, 1(2), pp.53–59.
- KEMENTERIAN PERHUBUNGAN REPUBLIK INDONESIA, 2024. *Sistem Informasi Angkutan Dan Sarana Transportasi Indonesia*. Kementerian Perhubungan Republik Indonesia.
- LEWIS, C.D., 1982. *Industrial and Business Forecasting Methods: A Practical Guide to Exponential Smoothing and Curve Fitting*. Butterworth scientific. Butterworth Scientific.

- MEILANIA, G.T., SEPTIANI, A.V., ERIANTI, E., NOTODIPUTRO, K.A. AND ANGRAINI, Y., 2024. Pemodelan ARIMA-GARCH dalam Peramalan Kurs Rupiah Terhadap Yen dengan Masalah Keheterogenan Ragam. *Ekonomis: Journal of Economics and Business*, 8(1), pp.165–180. <https://doi.org/10.33087/ekonomis.v8i1.1294>.
- PANJAITAN, H., PRAHUTAMA, A. AND SUDARNO, 2018. Peramalan Jumlah Penumpang Kereta Api Menggunakan Metode ARIMA, Intervensi Dan ARFIMA (Studi Kasus: Penumpang Kereta Api Kelas Lokal Ekonomi DAOP IV Semarang). *JURNAL GAUSSIAN*, [online] 7(1), pp.96–109. Available at: <<https://ejournal3.undip.ac.id/index.php/gaussian/>>.
- PONTOH, R.S., ZAHROH, S., NURAHMAN, H.R., APRILLION, R.I., RAMDANI, A. AND AKMAL, D.I., 2021. Applied of feed-forward neural network and facebook prophet model for train passengers forecasting. In: *Journal of Physics: Conference Series*. IOP Publishing Ltd. <https://doi.org/10.1088/1742-6596/1776/1/012057>.
- PRAKOSO, F.B., DARMAWAN, G. AND BACHRUDIN, A., 2023. Penerapan Metode Facebook Prophet Untuk Meramalkan Jumlah Penumpang Trans Metro Bandung Koridor 1. *ARMADA: Jurnal Penelitian Multidisiplin*, 1(3), pp.133–147. <https://doi.org/10.55681/armada.v1i3.416>.
- PUTRI, T.A.E., WIDIHARIH, T. AND SANTOSO, R., 2023. Penerapan Tuning Hyperparameter Randomsearchcv Pada Adaptive Boosting Untuk Prediksi Kelangsungan Hidup Pasien Gagal Jantung. *Jurnal Gaussian*, 11(3), pp.397–406. <https://doi.org/10.14710/j.gauss.11.3.397-406>.
- RAHMAN, A.T.M.S., HOSONO, T., KISI, O., DENNIS, B. AND IMON, A.H.M.R., 2020. A minimalistic approach for evapotranspiration estimation using the Prophet model. *Hydrological Sciences Journal*, pp.1994–2006. <https://doi.org/10.1080/02626667.2020.1787416>.
- RAIHAN, A., SUHENDI, A. AND BETHANINGTYAS, H., 2023. Implementasi Metode Prophet pada Prediksi Tinggi Air Sungai. *e-Proceeding of Engineering*, 10(5), p.4412.
- SALSABILA, A. AND KESUMAWATI, A., 2023. Peramalan Jumlah Kedatangan Penumpang Pesawat Internasional di Bandara Soekarno-Hatta Menggunakan Metode Double Exponential Smoothing. *Emerging Statistics and Data Science Journal*, 1(2).
- SRIVASTAVA, S., 2019. Benchmarking of Facebook's Prophet, PELT and Twitter's Anomaly detection and automated de-ployment to cloud. University of Twente.
- SUKMA, R.A., 2024. Penerapan Algoritma Prophet Untuk Peramalan Jangka Pendek Kurs Mata Uang Rupiah (IDR) Ke Dolar Amerika Serikat (USD). IPB University.
- TAYLOR, S.J. AND LETHAM, B., 2017. Forecasting at Scale. *PeerJ*. [online] <https://doi.org/10.7287/peerj.preprints.3190v2>.
- ŽUNIĆ, E., KORJENIĆ, K., HODŽIĆ, K. AND ĐONKO, D., 2020. Application of Facebook's Prophet Algorithm for Successful Sales Forecasting Based on Real-world Data. *International Journal of Computer Science and Information Technology (IJCSIT)*, 12(2), pp.23–36. <https://doi.org/10.5121/ijcsit.2020.12203>.